

Naïve Bayes & k-NN classifier

Jehyuk Lee

Department of Data Science

Kookmin University

Contents

- 1. Naïve Bayes Classifier
- 2. k-nearest neighbor(kNN) classifier

1. Naïve Bayes Classifier

Bayesian Classification

- 조건부 확률 (Conditional Probability)

- 어떤 사건(A)이 발생한 상태에서 다른 사건(B)가 발생할 확률

$$P(B|A) = \frac{P(A, B)}{P(A)}$$

Bayesian Classification

- **Problem Statement (Classification)**

- 우리에게 n 개의 feature X_1, X_2, \dots, X_n 가 있다고 해볼게요.
- 이 때, 해당 데이터의 Y 의 값을 예측해야 합니다.
- 이를 수식으로 표현하면, 다음과 같이 나타낼 수 있습니다.

$$\underset{Y}{\operatorname{argmax}} P(Y|X_1, X_2, \dots, X_n)$$

Bayesian Classification

- Problem Statement (Classification)

- 우리에게 n 개의 feature X_1, X_2, \dots, X_n 가 있다고 해볼게요.
- 이 때, 해당 데이터의 Y 의 값을 예측해야 합니다.
- 이를 수식으로 표현하면, 다음과 같이 나타낼 수 있습니다.

$$\underset{Y}{\operatorname{argmax}} P(Y|X_1, X_2, \dots, X_n)$$

n 개의 feature값이 주어졌을 때,
레이블이 각 Y 값이 될 확률을 구하고,
그 확률 값이 가장 큰 Y 로 분류하세요

Bayesian Classification

- Problem Statement (Classification)

- 우리에게 n 개의 feature X_1, X_2, \dots, X_n 가 있다고 해볼게요.
- 이 때, 해당 데이터의 Y 의 값을 예측해야 합니다.
- 이를 수식으로 표현하면, 다음과 같이 나타낼 수 있습니다.

$$\underset{Y}{\operatorname{argmax}} P(Y|X_1, X_2, \dots, X_n)$$

n 개의 feature값이 주어졌을 때,
레이블이 각 Y 값이 될 확률을 구하고,
그 확률 값이 가장 큰 Y 로 분류하세요

현재 우리는 이 값을 알지 못해요.
(오히려 이 값을 알고 싶어요.)

Bayesian Classification

- **Class Conditional Independence Assumption**

- 잠시, argmax부분은 빼고 수식만 보겠습니다.
- $Y=i$ 일 때 수식 값은 다음과 같습니다.

$$P(Y = i | X_1, X_2, \dots, X_n) = \frac{P(X_1, X_2, \dots, X_n | Y = i)P(Y = i)}{P(X_1, X_2, \dots, X_n)}$$

Bayesian Classification

- **Class Conditional Independence Assumption**

- 잠시, argmax부분은 빼고 수식만 보겠습니다.
- $Y=i$ 일 때 수식 값은 다음과 같습니다.

$$\boxed{\overset{\text{Posterior}}{P(Y = i | X_1, X_2, \dots, X_n)}} = \frac{\overset{\text{Likelihood}}{P(X_1, X_2, \dots, X_n | Y = i)} \overset{\text{Prior}}{P(Y = i)}}{P(X_1, X_2, \dots, X_n)}$$

Prior: class가 i 일 확률

Likelihood: Class가 i 일 때, 데이터가 발생할 확률

Posterior: 데이터가 주어졌을 때, Class가 i 일 확률

Bayesian Classification

- **Class Conditional Independence Assumption**

- 잠시, argmax부분은 빼고 수식만 보겠습니다.
- $Y=i$ 일 때 수식 값은 다음과 같습니다.
- 분모 부분을 다음과 같이 각 Y 에 대해서 조건부 확률을 더해준 값으로 변경 가능합니다.

$$P(Y = i | X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) = \frac{P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n | Y = i)P(Y = i)}{P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n)}$$
$$= \frac{P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n | Y = i)P(Y = i)}{\sum_j P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n | Y = j)}$$

변수 X_1 의 값이 x_1 , X_2 의 값이 x_2, \dots 일 때,
클래스 Y 가 i 일 확률

분자에 있는 term을 모든 class에 대해서
합산한 결과일 뿐입니다!

Bayesian Classification

- **Class Conditional Independence Assumption**

- 잠시, argmax부분은 빼고 수식만 보겠습니다.
- $Y=i$ 일 때 수식 값은 다음과 같습니다.
- 분모 부분을 다음과 같이 각 Y 에 대해서 조건부 확률을 더해준 값으로 변경 가능합니다.

$$P(Y = i | X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) = \frac{P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n | Y = i)P(Y = i)}{P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n)}$$

이 term을 잠시 보겠습니다!

$$= \frac{P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n | Y = i)P(Y = i)}{\sum_j P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n | Y = j)}$$

Bayesian Classification

- **Class Conditional Independence Assumption**

- $P(X_1, X_2, \dots, X_n|Y)$ 를 직접 모델링하여 구하는 것은 너무 어렵습니다.
 - N 이 커질수록 엄청나게 많은 X 조합이 생기기 때문이죠.
- 그래서 각 속성은 서로 독립이라고 가정합니다.
 - 이러한 가정하에, 단변량 조건부 확률의 곱으로 나타냅니다.

$$P(X_1, X_2, \dots, X_n|Y) = P(X_1|Y)P(X_2|Y) \cdots P(X_n|Y)$$

Under class conditional Independence Assumption

Bayesian Classification

- 자, 다시 원래수식으로 돌아가면...

- 잠시, argmax부분은 빼고 수식만 보겠습니다.
- $Y=i$ 일 때 수식 값은 다음과 같습니다.
- 분모 부분을 다음과 같이 각 Y 에 대해서 조건부 확률을 더해준 값으로 변경 가능합니다.

$$\begin{aligned} P(Y = i | X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) &= \frac{P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n | Y = i) P(Y = i)}{P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n)} \\ &= \frac{P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n | Y = i) P(Y = i)}{\sum_j P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n | Y = j)} \\ &= \frac{\prod_{k=1}^n P(X_k = x_k | Y = i) \cdot P(Y = i)}{\sum_j \prod_{k=1}^n P(X_k = x_k | Y = j) \cdot P(Y = j)} \end{aligned}$$

Bayesian Classification

- 자, 다시 원래수식으로 돌아가면...

- 잠시, argmax부분은 빼고 수식만 보겠습니다.
- $Y=i$ 일 때 수식 값은 다음과 같습니다.
- 분모 부분을 다음과 같이 각 Y 에 대해서 조건부 확률을 더해준 값으로 변경 가능합니다.

$$\begin{aligned} P(Y = i | X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) &= \frac{P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n | Y = i) P(Y = i)}{P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n)} \\ &= \frac{P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n | Y = i) P(Y = i)}{\sum_j P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n | Y = j)} \\ &= \frac{\prod_{k=1}^n P(X_k = x_k | Y = i) \cdot P(Y = i)}{\sum_j \prod_{k=1}^n P(X_k = x_k | Y = j) \cdot P(Y = j)} \end{aligned}$$

Bayesian Classification

- 예제: 스팸메일 분류기

- 입력 텍스트(메일 본문)이 주어졌을 때, 해당 메일이 스팸인지 아닌지를 분류

- $P(Mail_{normal}|Text)$: 입력 텍스트가 주어졌을 때, 정상 메일일 확률

- $P(Mail_{spam}|Text)$: 입력 텍스트가 주어졌을 때, 스팸 메일일 확률

- 분류 기준

- $P(Mail_{normal}|Text) > P(Mail_{spam}|Text) \rightarrow \text{Normal!}$

- $P(Mail_{normal}|Text) \leq P(Mail_{spam}|Text) \rightarrow \text{Abnormal!}$

Bayesian Classification

• 예제: 스팸메일 분류기

– 입력 텍스트(메일 본문)이 주어졌을 때, 해당 메일이 스팸인지 아닌지를 분류

- $P(Mail_{normal}|Text)$: 입력 텍스트가 주어졌을 때, 정상 메일일 확률
- $P(Mail_{spam}|Text)$: 입력 텍스트가 주어졌을 때, 스팸 메일일 확률

– By Bayes Theorem,

- $$P(Mail_{normal}|Text) = \frac{P(Text|Mail_{normal})P(Mail_{normal})}{P(Text)}$$

- $$P(Mail_{spam}|Text) = \frac{P(Text|Mail_{spam})P(Mail_{spam})}{P(Text)}$$

Bayesian Classification

• 예제: 스팸메일 분류기

- 입력 텍스트(메일 본문)이 주어졌을 때, 해당 메일이 스팸인지 아닌지를 분류
 - $P(Mail_{normal}|Text)$: 입력 텍스트가 주어졌을 때, 정상 메일일 확률
 - $P(Mail_{spam}|Text)$: 입력 텍스트가 주어졌을 때, 스팸 메일일 확률
- By Class Conditional Independence Assumption, (Text : w_1, w_2, w_3 의 세 개의 단어만)

- $$P(Mail_{normal}|Text) \propto P(w_1|Mail_{normal})P(w_2|Mail_{normal})P(w_3|Mail_{normal})P(Mail_{normal})$$

일반 메일에서 단어 w_1 이 등장할 확률

- $$P(Mail_{spam}|Text) \propto P(w_1|Mail_{spam})P(w_2|Mail_{spam})P(w_3|Mail_{spam})P(Mail_{spam})$$

스팸 메일에서 단어 w_1 이 등장할 확률

Pros and Cons

- **Pros**

- 구현 및 실행이 쉽다
- 적은 학습 데이터에서도 성능이 괜찮다
 - (Class Conditional Independent Assumption은 매우 이상적인 가정임에도)

- **Cons**


- Class Conditional Independent Assumption을 만족시키기 어렵다
 - 대부분 변수간의 dependency가 존재
 - 어느정도 성능이 나오는 것이지, 좋은 성능이 나오기는 어렵다.

2. k-NN Classifier

K-nearest neighbor(k-NN) Classifier

- 특징


- 분류하려는 대상과 가장 가까운 k개의 데이터를 찾은 뒤, label들을 voting하여 분류



K-nearest neighbor(k-NN) Classifier

- 특징

- Distance Measure로 임의의 measure 함수를 사용 가능
 - Euclidean Distance
 - Cosine Distance



Pros and Cons

- **Pros**

- 간단한 모델이며 매우 직관적이다

- **Cons**

- 검색 비용이 크다
 - 학습 데이터의 수만큼 거리 계산을 함
 - Distance 함수를 잘 정의해야 함
 - 문제에 적합한 Distance 함수를 잘 정의하는게 중요

Summary

- **Naïve Bayes**

- Classification 문제: $\arg \max_Y P(Y|X_1, X_2, \dots, X_n)$
- Bayes Theorem을 이용하여, $Posterior \propto Prior \cdot Likelihood$ 로 표현
- Class Conditional Independence 가정하에서 Likelihood를 쉽게 계산이 가능하도록 함

- **k-NN**

- 분류하려는 대상과 가장 가까운 k개의 데이터를 찾은 뒤, label들을 voting하여 분류
- 임의의 distance measure를 사용할 수 있음 → 정교한 정의가 필요

End of the documents
